Curriculum Vitae

Mourad El Hamri

Doctorant en Informatique à l'Université Sorbonne Paris Nord

Page web : https://www.linkedin.com/in/elhamrimourad/

Candidat à un poste d'Attaché temporaire d'enseignement et de recherche

Profil « Machine Learning »

Université Sorbonne Paris Nord

Table des matières

Table des matières 2
1- Fiche de synthèse 3
2- Identité 3
3- Expérience Professionnelle 4
4- Formations et diplômes 5
4.1- Formation académique 5
4.2- Autres formations 5
5- Enseignement 6
5.1- Récapitulatif des activités d'enseignement 6
5.2- Description détaillée des enseignements 7
6- Recherche 9
6.1- Axes de recherche 9
6.2- Travaux effectués et connectivité entre les axes 10
7- Responsabilités 11
7.1- Responsabilités administratives 11
7.2- Encadrements 11
7.3- Évaluations 11
8- Publications 12

1- Fiche de synthèse

Carrière :

Doctorant en Informatique, à partir de Septembre 2019 sur contrat d'allocataire-moniteur

Principales publications :

Types	Acceptés	Soumis	En préparation
Revues internationales	1	2	1
Chapitres de livre	1	-	-
Conférences internationales	2	2	1
Conférences nationales	1	-	-
Total	**5**	**4**	**2**

Enseignement :
Travaux dirigés (TD) et pratiques (TP) enseignés à l'Institut Galilée de l'Université Sorbonne Paris Nord. **Total** 60h de TD et 132h de TP.

Thèmes de recherche :
Adaptation de domaine, Apprentissage semi-supervisé et Apprentissage collaboratif.

2- Identité

Nom : Mourad
Prénom : El Hamri
Adresse personnelle :
48 Boulevard Vital Bouhot
92200 Neuilly-sur-Seine
France

Date et lieu de naissance : 25/05/1994 à Fès, Maroc
Nationalité : Marocaine

Téléphone personnel : +33 6 95 15 07 63
E-mail : mourad.elhamri@outlook.fr
Page Web : https://www.linkedin.com/in/elhamrimourad/

Membre :
International Neural Network Society (INNS) .
Société Française de Statistique (SFdS).

3- Expérience Professionnelle

09/2019-../2022 Allocataire-moniteur en informatique, École doctorale Galilée, enseignement à l'Institut Galilée, recherche au LIPN, Université Sorbonne Paris Nord.

04/2019-09/2019 Stage de Master 2 recherche au LIPN, Université Sorbonne Paris Nord, sous la direction du Pr. Younès Bennani : « Apprentissage entre apprenants dans le cadre de la théorie du transport optimal ».

01/2017-06/2017 Stage de Licence 3 au Laboratoire d'Algèbre, Géométrie et Arithmétique (LAGA), Faculté des Sciences de Fès, sous la direction du Pr. Siham Ezzouak : « Cryptographie basée sur les courbes elliptiques ».

4- Formations et diplômes

4.1- Formation académique

2022 **Université Sorbonne Paris Nord, Laboratoire LIPN UMR 7030 CNRS**
Thèse de doctorat, spécialité informatique : « Théorie du transport optimal pour l'apprentissage par transfert et l'adaptation de domaine »
Directeur : Y. BENNANI Professeur, Université Sorbonne Paris Nord

2019 **Université Sorbonne Paris Nord, Master 2 recherche :** « Exploration Informatique des Données et Décisionnel »
Mention Bien

2019 **Université Sidi Mohamed Ben Abdellah, Master 2 recherche :** « Mathématiques Appliquées et Science des données »
Mention Bien

2017 **Université Sidi Mohamed Ben Abdellah, Licence :** « Sciences Mathématiques et Applications »
Mention Bien

4.2- Autres formations

2019-2022, formations doctorales :

- Computational Optimal Transport - ENS d'Ulm (2019-2020)
- Machine Learning - Université Sorbonne Paris Nord (2019-2020)
- Deep Learning - Université Sorbonne Paris Nord (2019-2020)
- Google Digital Garage (2019-2020)
- MATH & IA (1 journée)

5- Enseignement

5.1- Récapitulatif des activités d'enseignement

Table 5.1 : Récapitulatif des volumes horaires (Heures équivalent TD)

Lieu	Années	Statut	TD	TP	Total
Université Sorbonne Paris Nord Institut Galilée	2019-2020	Moniteur	24 h	40 h	64 h
	2020-2021	Moniteur	20 h	44 h	64 h
	2021-2022	Moniteur	16 h	48 h	64 h
Total			**60 h**	**132 h**	**192**

Table 5.2 : Récapitulatif des matières enseignées

Intitulé	Années	Type	Niveau	Volume
Science des données numériques	2021-2022	TP	Master 2 Informatique	15 h
Science des données numériques	2020-2021	TP	Master 2 Mathématiques	15 h
Deep Learning	2021-2022	TP	Master 2 Informatique	15 h
Deep Learning	2020-2021	TP	Master 2 Mathématiques	10 h
Bases de données	2020-2021	TD/ TP	Licence 3 Informatique	40 h
Programmation impérative	2020-2021	TP	Licence 1 PC-SPI	10 h
Algorithmique	2021-2022	TD/ TP	Licence 1 Math-Info	15 h
Algorithmique	2019-2020	TD/ TP	Licence 1 Math-Info	15 h
Programmation 1	2021-2022	TD	Licence 1 Math-Info	9 h
Programmation 1	2019-2020	TD	Licence 1 Math-Info	9 h
Programmation 1	2019-2020	TD	Licence 1 PC-SPI	9 h
Matlab	2019-2020	TP	Ingénieur 1ère	12 h
Préparation C2i	2019-2020	TP	Licence 1 Info	18 h

5.2- Description détaillée des enseignements

Science des données numériques
Niveau : Master 2 Informatique/Mathématiques
Responsable : Younès Bennani

- Matériel produit : Slides et polycopiés de cours, sujets de TP et sujets d'examens.
- Contenu : Méthodes Statistiques : méthodes bayesiennes, séparation linéaire et non linéaire, technique des plus proches voisins, méthodes de classification, méthodes de clustering, régression, méthodes hiérarchiques, traitements de caractéristiques, sélection de variables, pondération de variables, extraction de caractéristiques. Méthodes à base d'arbres et de graphes.

Deep Learning
Niveau : Master 2 Informatique/Mathématiques
Responsable : Younès Bennani

- Matériel produit : Slides et polycopiés de cours, sujets de TP et sujets d'examens.
- Contenu : Introduction au PyTorch, Transformation linéaire et non-linéaire, Perceptron, Multilayer perceptron, Adaline, Madaline, Autoencoder, Convolutional neural network (CNN), Generative adversarial network (GAN), Deep Embedded Self-Organizing Map (DeepSOM).

Bases de Données
Niveau : Licence Informatique 3ème année
Responsable : Guénaël Cabanes

- Contenu : Modèle relationnel : différence entre SGBD et fichiers, schéma, instance, contraintes, bases de données, notions de requêtes, vue et mise à jour, langage de requêtes : algèbre relationnelle, SQL, mise à jour des vues, rapport avec les entrepôts de données. Modèle entité association, diagramme E-A, contraintes, algorithme de transformation.

Matlab
Niveau : École d'ingénieurs 1ère année
Responsable : John Chaussard

- Contenu : Introduction à Matlab, Programmes simples avec Matlab, Interfaces graphiques et interpolation, Complexité, Tracé de graphes et probabilités, Convolution et transformée de Fourrier.

Programmation 1
Niveau : Licence 1 Informatique/Mathématiques
Responsable : Stefano Guerrini/Roland Grappe

- Contenu : introduction aux notions de variable et type, instruction élémentaire, structure de contrôle, définition et utilisation de fonctions simples pour structurer et clarifier un algorithme, utilisation de structures de données simples : types structurés (tableaux, structures, chaînes de caractères, etc.), programmation dans un langage de programmation impérative structuré.

Programmation impérative
Niveau : Licence 1 Informatique/Mathématiques
Responsable : Kais Klai

- Contenu : Pointeurs, Fonctions, Structures.

Algorithmique pour l'Algèbre linéaire
Niveau : Licence 1 Informatique/Mathématiques
Responsable : Joseph Ben Geloun

- Contenu : Double pointeurs, Complexité, Pivot de Gauss.

Préparation au C2i
Niveau : Licence 1 Informatique
Responsable : Mohamed Sait (DSI)

- Contenu : Outils multimédias et Interne

6- Recherche

6.1- Axes de recherche

Mes travaux de recherche peuvent être regroupés autour de trois axes majeurs, tous abordés en utilisant un outil mathématique très puissant et bien adapté : « **La théorie du transport optimal** », doté de nombreuses propriétés attrayantes pour comparer les mesures de probabilité dans un cadre Lagrangien. Dans les trois axes de recherche ci-dessous, je m'appuie sur cette théorie mathématique pour modéliser les tâches, calculer les solutions et fournir une analyse théorique des algorithmes.

1) **Axe privilégié - Adaptation de domaine** : L'apprentissage supervisé est sans doute la tâche la plus répandue du machine learning et a joui d'un grand succès dans un large éventail de champs d'application. Cependant, la plupart des méthodes d'apprentissage supervisé reposent sur l'hypothèse cruciale que les données d'apprentissage et de test sont tirées de la même distribution de probabilité. Dans les applications du monde réel, cette hypothèse est généralement violée pour plusieurs raisons qui dépendent de l'application. Ces changements de distribution sont susceptibles de dégrader considérablement la capacité de généralisation des modèles d'apprentissage supervisé. Bien que l'étiquetage manuel puisse sembler une solution réalisable, une telle approche n'est pas pratique, car il est souvent excessivement coûteux de collecter à zéro un nouvel ensemble de données étiquetées de grande qualité avec la même distribution que les données de test, et ce serait un immense gâchis de rejeter totalement les connaissances disponibles sur un ensemble d'apprentissage étiqueté différent, mais connexe. Cette situation problématique a favorisé l'émergence de l'adaptation de domaine, une sous-catégorie de la théorie de l'apprentissage statistique qui tient compte du changement de distribution entre les données d'apprentissage et de test respectivement appelées domaines source et cible. Il existe deux variantes du problème d'adaptation de domaine, l'adaptation de domaine non supervisée, où toutes les données cibles sont non étiquetées, et l'adaptation de domaine semi-supervisée, où peu de données cibles étiquetées sont disponibles. Mon activité de recherche concerne le problème épineux d'adaptation de domaine non supervisée.

2) **Apprentissage semi-supervisé** : En conjonction avec l'adaptation de domaine, l'apprentissage semi-supervisé constitue une approche attrayante pour remédier au manque d'ensembles de données étiquetées. Il vise à réduire considérablement le besoin d'échantillons étiquetés en fournissant un moyen d'exploiter conjointement les instances non étiquetées. Mes travaux de recherches touchent à la fois l'apprentissage semi-supervisé transductif où on s'intéresse exclusivement à l'obtention de labels pour les données non étiquetés présentes dans la phase d'apprentissage et l'apprentissage semi-supervisé inductif où on cherche à inférer un bon classifieur capable d'estimer efficacement l'étiquette de n'importe quelle donnée dans l'espace d'entrée, même pour des données non vus auparavant.

3) **Apprentissage collaboratif non supervisé** : Un nombre important de nouveaux algorithmes de clustering a été développé ces dernières années, et des méthodes existantes ont également été modifiées et améliorées. Cette abondance de méthodes peut être expliquée par la difficulté de proposer des méthodes génériques s'adaptant à tous les types de données disponibles. En effet, chaque méthode comporte un biais induit par l'objectif choisi pour créer les clusters. La collaboration entre méthodes de clustering peut mener à deux types de résultats, soit un partitionnement unique des données, soit un ensemble de résultats de clustering. Mon activité de recherche se focalise sur les techniques de fusion ou de combinaison de résultats de clustering.

6.2- Travaux effectués et connectivité entre les axes

Depuis le début de ma thèse, j'ai proposé plusieurs nouveaux algorithmes pour résoudre les problèmes liés à chaque axe. Tous ces algorithmes sont basés sur la théorie du transport optimal.

Pour l'adaptation du domaine non-supervisé, une approche qui relie les notions de transport optimal, d'apprentissage de mesures de probabilités et d'apprentissage non supervisé a été proposée. Cette approche est basée sur une formulation hiérarchique du transport optimal, qui exploite, au-delà des informations géométriques capturées par la métrique au sol, des informations structurelles plus riches dans les domaines source et cible. Les informations structurelles dans le domaine source sont formées instinctivement en regroupant les échantillons en structures selon leurs étiquettes de classe. L'exploration des structures cachées dans le domaine cible non étiqueté est réduite au problème d'apprentissage de mesure de probabilité par le barycentre de Wasserstein, que j'ai prouvé être équivalent au clustering spectral. Les expériences ont montré la supériorité de l'approche proposée par rapport à l'état de l'art.

Pour l'apprentissage semi-supervisé, une approche qui effectue dans un processus incrémental, la propagation de labels à travers un graphe bipartite complet a été proposée. La matrice d'affinité de ce graphe est construite à partir du plan de transport optimal entre les mesures empiriques définies sur les données étiquetées et non étiquetées. L'algorithme assure un haut degré de certitude des prédictions en contrôlant le processus de propagation à l'aide d'un score de certaineté basé sur l'entropie de Shannon. Les expériences ont montré la supériorité de l'approche proposée par rapport à l'état de l'art.

En lien avec l'axe privilégié d'adaptation de domaine, j'ai proposé un algorithme qui cherche un sous-espace conjoint des domaines source et cible en utilisant des projections supervisées qui préservent la localité, de sorte que les projections des données dans cet sous-espace latent puissent être à la fois invariantes par rapport au domaine et discriminantes. Cet objectif peut toutefois être assez difficile à atteindre en raison de l'absence de données étiquetées dans le domaine cible. Pour surmonter ce défi, nous avons utilisé l'approche semi-supervisée décrite dans le paragraphe précédent afin d'effectuer un pseudo-étiquetage sélectif pour les données cibles. Les données cibles pseudo-étiquetées sélectionnées sont ensuite combinées avec les données sources pour apprendre de manière progressive l'alignement des deux domaines. Les expériences ont montré la compétitivité de l'approche proposée par rapport aux méthodes de l'état de l'art.

Concernant l'axe d'apprentissage collaboratif, une approche qui consiste à transférer les connaissances entre les modèles a été proposée, pour trouver un partitionnement unique et de meilleur qualité en se basant sur le barycentre de Wasserstein entre les différents collaborateurs.

En lien avec l'axe privilégié d'adaptation de domaine, nous menons un travail sur l'adaptation de domaine multi-source, où les données étiquetées disponibles peuvent provenir de plusieurs domaines avec des distributions différentes. Par conséquent, l'application naïve d'algorithmes d'adaptation de domaine mono-source peut conduire à des solutions sous-optimales. Afin d'optimiser la qualité d'adaptation nous mettons en œuvre un algorithme qui tente de construire un domaine intermédiaire entre les domaines sources et le domaine cible. Cette méthode s'appuie sur l'apprentissage collaboratif pour agréger les distributions de probabilité des domaines sources. Une fois que le consensus ou l'agrégation des distributions sources est trouvé, nous procédons par résoudre un problème d'adaptation du domaine standard.

7- Responsabilités

7.1- Responsabilités administratives

J'ai eu la responsabilité, pendant 2 ans (2020-2022), du Séminaire Junior de la composante ADA, équipe A3, LIPN.

J'ai été, en 2021, président de la séance «Semi-supervised Learning» de la conférence IJCNN'21-Shenzhen, China.

7.2- Encadrements

J'ai été chargé en 2021 de la co-supervision d'un étudiant de Master 2 Informatique de l'Université Sidi Mohamed Ben Abdellah (Maroc) dans le cadre d'une mobilité Erasmus+ de 4 mois à l'Université Sorbonne Paris Nord.

À partir d'avril 2022, je co-supervise un autre étudiant de Master 2 Informatique de l'Université Sidi Mohamed Ben Abdellah (Maroc) dans le cadre d'une mobilité Erasmus+ de 4 mois à l'Université Sorbonne Paris Nord.

7.3- Évaluations

J'ai évalué des articles pour les revues suivantes :

- Knowledge and Information Systems

Ainsi que des articles pour des conférences internationales suivantes:

- IJCNN (International Joint Conference on Neural Networks)
- ICONIP (International Conference on Neural Information Processing)
- ESANN (European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning)

8- Publications

Table 8.1 : Récapitulatif des publications

Types	Acceptés	Soumis	En préparation
Revues internationales	1	2	1
Chapitre de livre	1	-	-
Conférences internationales	2	2	1
Conférences nationales	1	-	-
Total	**5**	**4**	**2**

8.1- Revues internationales avec comité de sélection

Ben Bouazza, F., Bennani, Y., El Hamri, M.: *Multi-view Clustering Through Optimal Transport.* Australian Journal of Intelligent Information Processing Systems (2019).

El Hamri, M., Bennani, Y., Falih, I., Ahaggach, H.: *Hierarchical Optimal Transport for Unsupervised Domain Adaptation.* Machine Learning Journal. Soumis.

El Hamri, M., Bennani, Y., Falih, I.: *Transport Optimal pour l'apprentissage semi-supervisé.* Revue des Nouvelles Technologies de l'Information, Soumis.

8.2- Chapitres de livres

Ben Bouazza, F., Bennani, Y., El Hamri, M.: *An Optimal Transport framework for Collaborative Multi-View Clustering*. In: Recent Advancements in Multi-View Data Analytics, Witold Pedrycz, Shyi-Ming Chen (Ed.), Springer Cham (2022).

8.3- Conférences internationales avec comité de sélection

El Hamri, M., Bennani, Y., Falih, I.: *Label Propagation Through Optimal Transport.* Proceeding of the International Joint Conference on Neural Networks (IJCNN'21), pp. 2659-2664, Shenzhen, China (2021).

El Hamri, M., Bennani, Y., Falih, I.: *Inductive Semi-supervised Learning Through Optimal Transport.* International Conference on Neural Information Processing (ICONIP'21), pp. 668-675, Bali, Indonesia (2021).

El Hamri, M., Bennani, Y., Falih, I.: *Incremental Unsupervised Domain Adaptation through Optimal Transport.* Proceeding of the International Joint Conference on Neural Networks (IJCNN'22). Soumis

El Hamri, M., Bennani, Y., Falih, I.: *When Domain Adaptation Meets Semi-Supervised Learning Through Optimal Transport.* Proceeding of the International Conference on Artificial Intelligence

Applications & Innovations (AIAI'22). Soumis

8.4- Conférences nationales avec comité de sélection

El Hamri, M., Bennani, Y., Falih, I..: *Apprentissage semi-supervisé transductif basé sur le transport optimal.* Conférence Internationale Francophone sur la Science des Données (CIFSD'21), Marseille, France (2012).

8.5- Prix et distinctions

- Prix du meilleur article à la conférence CIFSD'21